

【基础概念】:

模型:

- 输入与输出的数学关系
- 一个机器学习模型 --> 能够针对之前没有有接触到的数据集进行 pattern 识别或决策

机器学习 (Tom Mitchell): ($ax_1+bx_2+cx_3+error=y$)

- 计算机的算法 --> 通过经验自发提升自己。
 - “the study of computer algorithms that automatically improve through experiences.”
 - 经验 Experience (E):
 - ◆ 算法所接触到的数据或信息
 - ◆ x_1, x_2, x_3
 - 任务 Tasks (T):
 - ◆ 算法具体的目标
 - ◆ y
 - 表现 Performance measure (P):
 - ◆ 衡量算法完成目标的好坏
 - 提升 Improvement/Learning:
 - ◆ 算法会因为 E 的增加而提升对应的 P
 - ◆ 一个计算机算法在 “学习” --- 如果算法的 Performance 通过经验 (E) 得到了提升

同等重要:

- 深入场景+特征场景
 - 基本特征工程
 - ◆ Encoding 标记
 - ◆ Handling missing 缺失处理
 - ◆ Feature transformation (classic) 特征转换
 - Scaling/normalization (classic) 特征缩放、标准化、正则化
 - 晋级特征工程
 - ◆ Feature creating/deleting 特征生成、删除 →→→ 样本平衡、新释义特征
 - ◆ Dimensionality reduction (PCA) 主成分分析
 - ◆ ML-models themselves 机器学习模型本身
 - ◆ Feature-arrangements 特征排列处理

算法分类:

- 非监督
 - Clustering:
 - ◆ K-means clustering
 - ◆ Hierarchical clustering 等级
 - ◆ DBSCAN 基于密度空间
 - Association rule learning 关联规则学习
 - Dimensionality reduction 降维
 - ◆ PCA 主成分分析
 - ◆ t-Distributed stochastic neighbor embedding (t-SNE) 2\3d 图像可视化高维数据
- 监督
 - Logistic regression
 - Decision tree --> random forest → XGBoost + lightGBM
 - Support vector machine
 - Neural networks (引出为什么使用深度神经网络)
- 深度神经网络

- 自然语言（NLP）
- 强化学习--- Several days later

	经典机器学习	深度神经网络（modern NLP）	强化学习
优点	可控性强 实时性强 先锋探索、特征选择	能应对复杂场景 多维多类数据	能应对非常复杂场景
缺点	无法应对大数据、太过复杂的数据或场景 训练数据单一	建模耗时 黑盒子场景	建模非常非常耗时 建模非常非常耗数据 半黑盒子场景
适用场景	需要立刻建模，并让模型预测的场景 经典预测判断场景	复杂场景、数据格式非主流场景	所有机器学习场景、特别是复杂场景

【深入场景+特征工程】



特征工程：将原始数据集转换为模型更易理解的数据集


(1) 场景专家很重要

- 先专家 + 后续特征筛选

(2) 各类的统计方法

- 基本特征工程

- Encoding 标记
- Handling missing 缺失处理
- Feature transformation (classic) 特征转换
 - Scaling/normalization (absolute-max, min-max, **z-score**...) 特征缩放、标准化



$$Z = \frac{x - \mu}{\sigma}$$

Z = standard score
 x = observed value
 μ = mean of the sample
 σ = standard deviation of the sample

- 晋级特征工程

- Feature creating/deleting 特征生成、删除 →→→ 样本平衡、新释义特征
 - SMOTH/ADASYN
 - Logarithm、Polynomial、higher-order interaction
- Dimensionality reduction (PCA) 主成分分析
- *ML-models themselves* 机器学习模型本身
- Feature-arrangements 特征排列处理
 - → 3D, 4D

不那么精确可靠,但可以拿到一个关于数据系统性展示.


- 推荐系统
- NLP 自然科学语言
 - o 如:新闻分类
- 图像录像分析
 - o 物体识别
- 异常识别:
- 用户分类、购买推荐

Clustering:

K--means clustering

建模方式:


- (1) 选择你要几个簇 k
- (2) 随便定义 k 个点做为每个簇的中心
- (3) 通过计算每个簇中心和每个样本点的距离 → 确认样本属于哪个簇
- (4) 重复(2)+(3)拿到很多簇 → 选择 variation 最平均的簇



确认 K 的方式:


- 每个 k 都重复建模确认簇 → 簇的增加 → Variation 减少 → [斗降点]

The total variation within each cluster is less than when K=3



Supervised learning → → → KNN

Hierarchical clustering 等级



DBSCAN 基于密度空间

Association rule learning 关联规则学习 → setOccur / 总 Set 数

- 用来发现数据集中不同项目之间的关联
- 识别频繁出现的模式和关联
- 以“如果-那么”表示 (如:商品、病症)
- (1) 设定“最小支持阈值” → 拿到所有 set 高于这个阈值 → sort

User ID	Movies liked
46578	Movie1, Movie2, Movie3, Movie4
98989	Movie1, Movie2
71527	Movie1, Movie2, Movie4
78981	Movie1, Movie2
89192	Movie2, Movie4
61557	Movie1, Movie3

Potential Rules:	Movie1 → Movie2
	Movie2 → Movie4
	Movie1 → Movie3



Transaction ID	Products purchased
46578	Burgers, French Fries, Vegetables
98989	Burgers, French Fries, Ketchup
71527	Vegetables, Fruits
78981	Pasta, Fruits, Butter, Vegetables
89192	Burgers, Pasta, French Fries
61557	Fruits, Orange Juice, Vegetables
87923	Burgers, French Fries, Ketchup, Mayo

Potential Rules:	Burgers → French Fries
	Vegetables → Fruits
	Burgers, French Fries → Ketchup

Dimensionality reduction 降维


■ PCA 主成分分析

- ◆ 目的:
 - 降维同时 + 最大可能 → 保留原始数据集信息
 - Maximize variation
- ◆ 用法:
 - 原始特征 – [variation analysis] → 主成分 (新特征)
 - 主成分 – [correlation analysis] → 原始特征
- ◆ 术语:
 - Eigen-vector 特征向量
 - 根据重要性排列 components




■ t-Distributed stochastic neighbor embedding (t-SNE) 2\3d 图像可视化高维数据

◆ 降多维数据集在 2、3d 图像中表达出来



■ Factor Analysis 因素分析




Please indicate how strongly the following characteristics apply to you. I am...

	applies	rather applies	partially applies	rather not applies	does not apply	
outgoing	☐	☐	☐	☐	☐	Extraversion
sociable	☐	☐	☐	☐	☐	
hard-working	☐	☐	☐	☐	☐	Conscientiousness
dutiful	☐	☐	☐	☐	☐	
warm-hearted	☐	☐	☐	☐	☐	Agreeableness
helpful	☐	☐	☐	☐	☐	

逻辑回归 Logistic Regression

传统统计 + statistics

There's a whole StatQuest on maximum likelihood (so see that for details), but in a nutshell...



$$\hat{y} = b_1 \cdot x_1 + b_2 \cdot x_2 + \dots + b_k \cdot x_k + a$$

$$f(z) = \frac{1}{1 + e^{-z}}$$

概率+特征线性关系

Thus, the **probability** that the dependent variable is 1 is given by this equation for given values of the **independent variables**:

$$P(y = 1 | x_1, \dots, x_n) = \frac{1}{1 + e^{-(b_1 \cdot x_1 + \dots + b_k \cdot x_k + a)}}$$

DATAtab

$$P(is\ diseased) = \frac{1}{1 + e^{-(b_1 \cdot Age + b_2 \cdot Male + b_3 \cdot Smoker + a)}}$$

Now we need to determine the **coefficients** so that our model best represents the given data.

To solve this problem, the so-called **maximum likelihood method** is used.

For this purpose, there are good **numerical methods** that can solve the problem efficiently.

The most important parameters are the **coefficient B**, the **p-value** and the **odds ratio**.

Model						
Copy Word	Copy Excel					
	Coefficient B	Standard error	z	p	Odds Ratio	95% conf. interval
Age	0.04	0.03	1.68	.092	1.04	0.99 - 1.1
Male	0.87	0.8	1.08	.28	2.39	0.49 - 11.55
Smoker	1.34	0.79	1.7	.089	3.81	0.82 - 17.76
Constant	-2.73	1.26	2.16	.03		

For example, the **odds ratio** of 1.04 means that a one **unit increase** in the variable age **increases the probability** that a person is sick by **1.04 times**.

Model						
Copy Word	Copy Excel					
	Coefficient B	Standard error	z	p	Odds Ratio	95% conf. interval
Age	0.04	0.03	1.68	.092	1.04	0.99 - 1.1
Male	0.87	0.8	1.08	.28	2.39	0.49 - 11.55
Smoker	1.34	0.79	1.7	.089	3.81	0.82 - 17.76
Constant	-2.73	1.26	2.16	.03		

Now comes the **Chi² test**.

Here we can read whether the **model** is **significant** or not.

Chi-Squared Test

Copy Word	Copy Excel		
Chi2	df	p	
8.79	3	.032	

输入: 1 0 1 0

输出: 1 0 0 1

多个类别:

- One-versus-One
- One-versus-Rest

Decision Tree → 随机森林 Random Forest → LightBGM/XGBoost

- 先锋算法:

- 分类
- Regression
- 特征筛选

- 决策树: 选择算法





- Gini Impurity (最常用)
- Information Gain
- Entropy (最敏感)

$$\text{Gini impurity} = 1 - \sum (p(i) * (1 - p(i)))$$



$$\text{Information Gain} = \text{Entropy}(\text{parent}) - [\text{Average entropy}(\text{children})]$$

$$\text{Entropy} = \sum_i -P_i(\log_2 P_i)$$

P_i is probability of class i










CALCULATE INFORMATION GAIN



支持向量机 Support vector machine

关键词:

- Hyperplane 超平面
- Margins 边
 - o 交叉验证 → Soft margin 软边
- Support Vector 支持向量



Kernels:

Linear	Polynomial	Radial Basis Function (RBF)	Sigmoid tahn
	d=degree 升维参数 coef 平方、立方、根、交互	Gamma (0,1) 约小约平滑,越大越 fit 零散数据 C 容错情况 无限维度 $k(x, x') = e^{-\gamma \ x - x'\ ^2}$ (RBF Kernel)	coef

Alg:

好处	不足
- 容错能力非常强	- 小数据集

多个类别:

- One-versus-One
- One-versus-Rest

[其它算法]:

Naïve Bayes

ARIMA, ARIMAX, SARIMA, SARIMAX

Lasso

[其它概念]:

惩罚函数 penalty:

- L1 正则化
- L2 正则化

Loss function:

- Focal_loss → data imbalance

模型测评方法:

Classic-scenes:

- Mis- classification rate
- MSE、MAE
- Entropy

NLP:

- 准确率、精确率(Precision)、召回率(Recall)、F1 分数
- 文本生成评估指标 (BLEU、ROUGE、困惑度)
- 语义质量评估 (词向量相似度、BERTScore)

*****Taiwanese Backruptcy-example*****

【非常重要】 ---> 筛选模型、参数算法 parametric optimization
http://www.ccbi.cmu.edu/reprints/Mason_Just_Psychological%20Science-2016_reprint_physics-concepts.pdf

【深度神经网络 Neural Network Processing】



【非常重要】---> 筛选模型、参数算法！

深度神经网络: 只要有足够数据 → 能针对世界上任何事情建模!

演化:

- 经典算法:
 - o 无法处理十万级+的样本级
 - o 处理复杂的情况、特征很难
- 定义:
 - o 人工神经网络, 由输入层、输出层以及它们之间的多层神经元组成
 - o 有很多不同类型样式的神经网络, 而所有网络都拥有的成分:

- **Neurons 神经元**
- **Synapses 突触**
- **Weights 权重**
- **Biases 偏差**
- **Functions 函数**




- 训练过程:
 - o 不知道边上的 weights、bias 具体值
→ 训练 → 更新对应值进行学习


激活函数

函数	公式	特点
Binary step	$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	阈值 → 决定激活还是不激活 不能用于多类分类问题 阶跃函数的梯度为零, 对反向传播造成阻碍
Linear activation	$f(x) = x$	激活就是输入 对反向传播造成阻碍, 导数是一个常数, 于如参特征无关 一旦用, 最后一层会是第一层的线性叠加
Sigmoid/Logistic	$f(x) = \frac{1}{1 + e^{-x}}$	将任何输入 scale down 到 0->1 之间 常用到需要预测 probability 平滑的梯度 → 防止结果条约
Tanh	$f(x) = \frac{(e^x - e^{-x})}{(e^x + e^{-x})}$	将任何输入 scale down 到 -1->1 之间 0 中心, 将输出映射成很负面、中立、很正面 经常在 hidden layer 出现. 帮助中心、标准化数据, 这样下一层学习更方便.
ReLU	$f(x) = \max(0, x)$	最常用 → 不同时激活所有神经元 → 允许 pattern + 算力高效 有导数, 允许反向传播. 神经元 deactivated 如果输入 < 0 ReLU 由于其线性、非饱和特性, 加速了梯度下降向损失函数的全局最小值的收敛。 [dying relu problem] 负面无倒数梯度, 部分神经元边可能永远不会

		更新
Leaky ReLU	$f(x) = \max(0.1x, x)$	Relu 增强版 解决 dying relu problem, 负数输入业务可以有导数被训练更新
Parametric ReLU	$f(x) = \max(ax, x)$	LeakRelu 失败将信息传递到下一个 layer
ELU	$\begin{cases} x & \text{for } x \geq 0 \\ \alpha(e^x - 1) & \text{for } x < 0 \end{cases}$	比 relu 梯度温和, 避免 dying relu problem [问题] 增添算力消耗, 梯度爆炸
Softmax	$\text{softmax}(z_i) = \frac{\exp(z_i)}{\sum_j \exp(z_j)}$	多个 sigmoid 的结合 → 计算相对概率 → 返回每个类的概率 多变量分类的最后一层
Swish	$f(x) = x * \text{sigmoid}(x)$	Google 发明 → 在难题(图像分类、翻译等)上多次比 relu 表现好 [好处] 平滑变化、不突变. 负数表达. 非单调 → 增强输入数据和带学习权重表达.
GELU	$f(x) = xP(X \leq x) = x\Phi(x) = 0.5x \left(1 + \tanh \left[\sqrt{2/\pi} (x + 0.044715x^3) \right] \right)$	非线性比 ReLU 和 ELU 好, 类似 NLP-Bert. 在计算机视觉、NLP、speech recognition 里面有优势.
SELU	$f(x) = \begin{cases} \alpha(e^x - 1) & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$	Hidden layer 内部的自正则化, 每一层保留几层均值、方差. 内部正则化 > 外部正则化, 方便汇聚收敛. CNN、RNN 常用



Layers	描述
Dense Layers 密集	实现全连接层，其中该层中的每个神经元都与前一层中的每个神经元相连。
Convolutional Layers 卷积	执行卷积运算，常用于图像处理。
Recurrent Layers 循环	处理序列数据，例如文本或时间序列。
Embedding Layers 嵌入	将分类数据映射到密集向量 (NLP)
Activation Layers 激活	应用激活函数，例如 ReLU、S 型函数或 tanh。
Normalization Layers 归一化	对输入数据进行归一化，提高训练稳定性。
Dropout Layers 丢弃层	在训练过程中随机丢弃神经元，防止过拟合。
LSTM	长短期记忆层，高效处理顺序数据 sequential data
INPUT	所有神经网络，明细输入维度
Flatten	降维，进入全连接层判断
GaussianNoise, ADD, Average, Subtract, CategoryEncoding, Cropping, Minimum	
RNN, Reshape, Resizing,	
.....	



知识总结 & 介绍个人经验

经典机器学习算法 – vs – 深度神经网络

- 数据 → NN 一般用什么数据
- 样本量
- 数据排列
- 深度神经网络
 - o Ambiguity & Intrigue
 - Grid-search so on optimization → **very important!**

***** past_work1


***** timing from monitor

(1) 前进程
→ 做预测

(2) 对比预测-

真是 → loss

$$\text{loss}(\text{Pred}, \text{Truth}) = E$$



(3) 反进程 back propagation → 计算每一个结点的梯度 gradient → 修改权重

Gradient
▽

Bigger gradients → bigger adjustments

深度神经网络

[深度]:


- 多个抽象的神经网络层 → 对于算法算力多种表达、应用 → 更高层次抽象
- 太多层次、类别的神经网络以及对应参数可以学习
 - o [必须]: 很多很多训练数据 + 非常快速的超级电脑
- 解决 - 非常困难的 ML 问题


问题

巨大开放挑战	过拟合, overfitting	Generalizability	Interpretability 理解性 & 解释性
选择一个正确的神经网络 “炼金术” → “化学” [努力学习]: - 降不同的结构和不同的问题关联	Dropout-layer Big data → 不是问题	大模型后续部分解决了	微观 - (怎么) → 宏观解决 非常非常复杂 百万、十亿万-free parameters: - 难以理解他们怎么工作,怎么得出结论 [反例]: - 安全、非常严格系统: 自驾车、机器人 - 解决: o 将物理学融入神经网络结构中

----- 受欢迎的神经网络结构 + 特点 -----

A Brief History of AI with Deep Learning






Optimizer:

Adam	SGD (stochastic gradient decent)
自适应矩阵估计、自适应梯度下降 - 动量 momentum 概念 - 自动为不同参数调整学习率 - 比 SGD 快 - 可能过拟合、泛化不如 SGD	随机梯度下降 - 每一步更新只使用一个或一小批样本，而不是正规数据集 - 大规模数据 - 手动调整学习率 - 收敛速度慢 - 噪声更大

(1) 多层感知器 Multiple layer perceptron


- 监督学习 tasks: 分类、回归
- activation function: Sigmoid, Relu, Tanh
- loss function: 熵值、MSE
- backpropagation: gradient decent calc




(2) Convolution neural network

- 卷积神经网络

- 擅长:
 - Detecting patterns → images, videos, audio signal
 - 对于转换、旋转(rotation)、scaling 不同能够处理
 - 不用特征抽取、处理
 - 大数据
- 缺点:
 - 算力、内存、MEM 损耗
 - 不够数据 → 过拟合
 - 需要大量的 labeled 数据
 - 不理解它怎么学的





(3) Recurrent neural network



- LSTM


→ 擅长:

- audio 声音信号、时序数据信号:
 - 因为时间而变化的信号变化
- 动态变化系统 dynamic system
- 自然语言处理
- 图像、影像处理
- Speech recognition

→ (LSTM,GRU)Feedback loop 反馈环+ Gates 门:

- 解决梯度消失(vanishing gradients)问题 → 有长期记忆





(4) Auto-Encoder


把信号和噪音分开

→ 结构:


- Encoder:
 - o 拿到输入 $\rightarrow$ 压缩为潜在空间表示
- Decoder:
 - o 将空间表示重新生成数据信号

→ 擅长:

- 识别相关的能提供信息的特征
- 降噪、提炼真正数据
- 异常探测 **Anomalies detections:**
 - o **Fault** 错误, **fraud** 欺骗, **intrusion** 侵入 **detection**



(5) GAN (Generative Advisory neuro network) 生成对抗网络



目标 → flower

Generator 发生器: (如:CNN)

- 发生器不停地生成“假数据”

→ 擅长:

- Video frame prediction 影像未来预测
- 未来预测
- 图像 enhance (低 resolution→高)
- 加密

- 不停尝试能否 fool 识别器
失败 → 更新梯度继续尝试

Discriminator 识别器: (如:CNN)

- 识别是不是真的花
失败 → 更新梯度继续判断

(6) Transformer – semi-supervised learning

https://itp.uni-frankfurt.de/~gros/StudentProjects/WS22_23_VisualTransformer/

- 自回归语言模型 → 生成类似人类的文本

- [一个序列] – 变换 → [另一个序列]

→ 示例: 翻译


→ > RNN:

- identify the context that bring meaning in each word in the sequence
- 多个 sequence 平行处理

→ 工作方式:

- Sequence-to-sequence learning、 auto-regressive 自回归(?)
- Take a sequence of tokens → predict the next word in the output sequence
- 主要结构:

- Encoder (映射输入序列 → 包含该输入的所有信息的抽象连续信息表示) → generates the encoder
- Decoder (拿到 encoder 的输入抽象表示 → 一步一步 → 生成单个输出, 同时接收先前的输出)
 - take all the encodings + uses derived context → generate output sequence



【自然语言处理 Natural Language Processing】

自然语言处理是人工智能的一个分支，专注于**研究计算机与人类通过语言进行的交互**。

- 结合人工智能技术 → 计算机**理解和生成人类语言**。

自然语言处理 (NLP) 也正在快速发展，尤其是通过整合**深度学习模型**，NLP 系统的准确性和效率得到了显著提升。**Transformer 模型**等创新彻底改变了翻译和文本生成等任务，使更复杂、更具备语境感知能力的 NLP 应用成为可能。

不足:


- 有效性很大程度上取决于每种语言是否**拥有全面且标注良好的数据集**。
- 在数字世界中，使用率较低的语言可能不如广泛使用的语言（例如英语、中文）拥有先进的 NLP 工具。

主要方面包括:

- **理解 understanding**
 - o 分析文本/语音 → 提取含义
 - o 识别实体并理解消息上下文
- **生成 generation**
 - o NLP 可用于创建文本、生成响应，甚至编写不同类型的内容。
- **运用 manipulation**
 - o 对语言操作:
 - 翻译
 - 摘要
 - 情感分析


NLP 是一种强大的工具，可用于商业、医疗保健、教育和研究等各个领域，以改善沟通、自动化和决策。运用例子包括:

- **聊天机器人**: NLP 为虚拟助手和聊天机器人提供支持，使其能够理解并响应用户查询。
- **搜索引擎**: NLP 帮助搜索引擎理解搜索查询的含义并提供相关结果。
- **机器翻译**: NLP 支持语言的自动翻译。
- **情感分析**: NLP 有助于分析文本或语音中表达的情感（积极、消极、中性）。
- **语音识别**: NLP 在将口语转换为文本的过程中发挥着至关重要的作用。





本质上：句子中单词的排列方式是无限的，而我们无法为计算机提供无限的词典。

→ 所以，将句子分解成多个部分 → 更容易处理




认知科学: 人类核心认知过程包括强化学习 (RL) 和工作记忆 (WM) 是人。RL 广义上指一组行为、神经科学和计算过程, 其中代理通过反复试验进行学习, 目标是最大化奖励

强化学习: 强化学习 (RL) 是一种机器学习技术, 它使机器人能够通过从经验中学习做出智能决策。通过接收程序化的奖励或惩罚, 驱动机器人的 AI 模型可以通过反复试验不断改进。



娟尾花 Iris-data-collection



娟尾花 Iris-data-collection

深度神经网络 + 强化学习 → 大模型



强化学习—过去经验

- (1) 相较于其它的机器学习模型，对大数据、多特征有显著优势
- (2) 智体的结构，以及策略函数选择对于可能对结果有特别显著且不同的影响

```
['/mnt/d/数据库/sensorless_drive/sensorless_drive_data.csv']
```

```
[get_convClassify_modelDraft1D]
```

```
[[1057 0 0 0 0 3 0 0 4 0 0]
[ 1 0 0 1 32 122 0 0 134 465 309]
[ 0 0 1054 2 1 7 0 0 0 0 0]
[ 0 0 69 980 0 0 1 0 0 14 0]
[ 0 0 331 153 141 0 0 438 1 0 0]
[260 0 68 0 0 330 0 68 338 0 0]
[ 0 0 0 1 0 0 1063 0 0 0 0]
[ 0 0 3 5 5 0 0 1051 0 0 0]
[12 0 5 0 0 19 0 2 1017 7 1]
[ 0 0 0 0 8 2 0 0 0 1052 2]
[ 0 0 0 0 0 0 0 0 0 0 1064]]
precision recall f1-score support
```

```
0.0 0.79 0.99 0.88 1064
1.0 0.00 0.00 0.00 1064
2.0 0.69 0.99 0.81 1064
3.0 0.86 0.92 0.89 1064
4.0 0.75 0.13 0.23 1064
5.0 0.68 0.31 0.43 1064
6.0 1.00 1.00 1.00 1064
7.0 0.67 0.99 0.80 1064
8.0 0.68 0.96 0.80 1063
9.0 0.68 0.99 0.81 1064
10.0 0.77 1.00 0.87 1064
```

```
accuracy 0.75 11703
macro avg 0.69 0.75 0.68 11703
weighted avg 0.69 0.75 0.68 11703
```

```
['/mnt/d/数据库/sensorless_drive/sensorless_drive_data.csv']
```

```
[get_image_model]
```

```
[[1053 0 0 0 0 0 11 0 0 0 0 0]
[ 0 1059 0 0 0 0 0 0 0 5 0]
[ 0 0 1059 0 5 0 0 0 0 0 0]
[ 0 0 0 1064 0 0 0 0 0 0 0]
[ 0 0 1 0 1059 0 0 4 0 0 0]
[ 2 0 0 0 0 1056 0 0 5 0 0]
[ 0 0 0 0 0 0 1064 0 0 0 0]
[ 0 0 1 0 7 0 0 1056 0 0 0]
[ 4 3 0 0 0 10 0 1 1045 1 0]
[ 0 12 0 0 0 0 0 0 0 1052 0]
[ 0 0 0 0 0 0 0 0 0 0 1064]]
precision recall f1-score support
```

```
0.0 0.99 0.99 0.99 1064
1.0 0.99 1.00 0.99 1064
2.0 1.00 1.00 1.00 1064
3.0 1.00 1.00 1.00 1064
4.0 0.99 1.00 0.99 1064
5.0 0.98 0.99 0.99 1063
6.0 1.00 1.00 1.00 1064
7.0 1.00 0.99 0.99 1064
8.0 1.00 0.98 0.99 1064
9.0 0.99 0.99 0.99 1064
10.0 1.00 1.00 1.00 1064
```

```
accuracy 0.99 11703
macro avg 0.99 0.99 0.99 11703
weighted avg 0.99 0.99 0.99 11703
```

```
['/mnt/d/数据库/sensorless_drive/sensorless_drive_data.csv']
```

```
[get_classify_modelTest]
```

```
[[1042 2 2 0 0 17 0 1 0 0 0]
[ 0 830 6 1 0 2 0 0 0 217 8]
[ 0 0 961 76 0 14 0 13 0 0 0]
[ 0 0 90 967 0 0 7 0 0 0 0]
[ 1 0 253 336 2 4 0 468 0 0 0]
[348 65 307 0 0 245 0 99 0 0 0]
[ 0 0 0 1 0 0 1063 0 0 0 0]
[ 21 0 20 64 0 8 6 945 0 0 0]
[260 190 364 3 2 99 0 143 0 2 0]
[ 0 233 1 0 0 2 0 0 0 828 0]
[ 0 0 0 0 0 0 0 0 0 0 1064]]
precision recall f1-score support
```


```
0.0 0.62 0.98 0.76 1064
1.0 0.63 0.78 0.70 1064
2.0 0.48 0.90 0.63 1064
3.0 0.67 0.91 0.77 1064
4.0 0.50 0.00 0.00 1064
5.0 0.63 0.23 0.34 1064
6.0 0.99 1.00 0.99 1064
7.0 0.57 0.89 0.69 1064
8.0 0.00 0.00 0.00 1063
9.0 0.79 0.78 0.78 1064
10.0 0.99 1.00 1.00 1064
```

```
accuracy 0.68 11703
macro avg 0.62 0.68 0.61 11703
weighted avg 0.62 0.68 0.61 11703
```

@润联

下回分解...

多模态融合模型 + 多模态融合大模型



→ 机器人领域使用的就是多模态模型 (VLA) visual-language-action

各类算法+模型+ML 技术的超级融合

